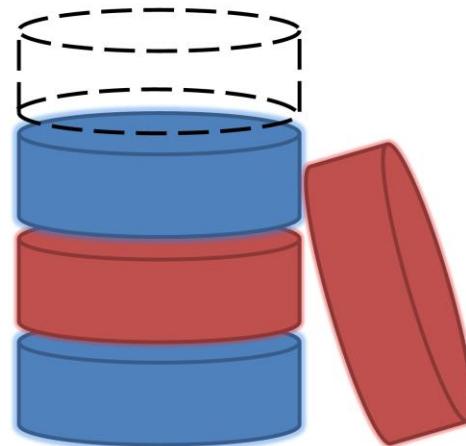


# Indecsi Organizare Directă



10

# Organizare directă a indecșilor

- *Organizarea directă* este o metodă de determinare a adresei unei înregistrări pe baza valorii unuia sau mai multor câmpuri (reprezentând, în general, cheia)
- **Caz ideal:** utilizarea unei funcții ce calculează adresa înregistrării (*funcție de dispersie*):

$$h: \{K_1, K_2, \dots, K_n\} \rightarrow A,$$

$h(K_i)$  = adresa celei de-a  $i$ -lea înregistrări

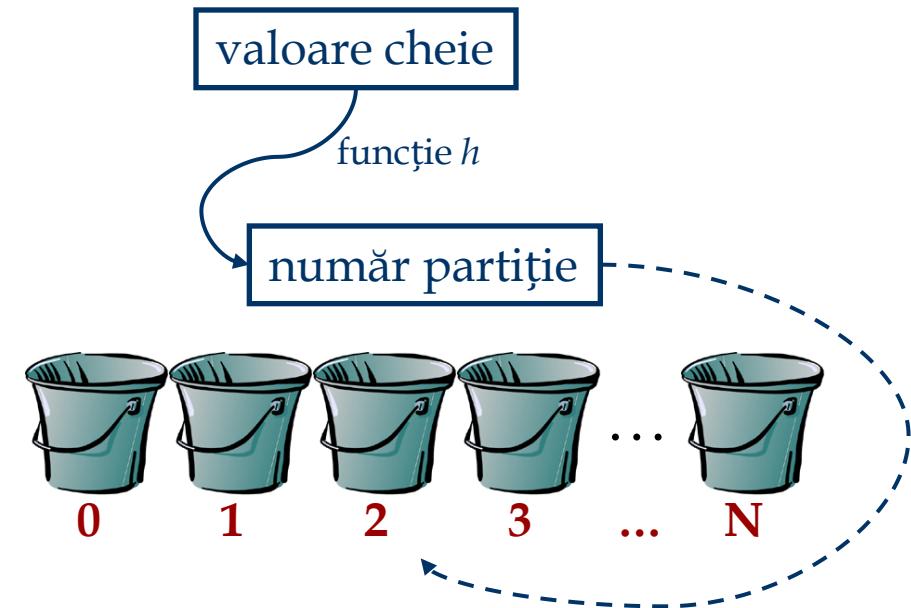
( $K_i$  e valoarea cheii înregistrării  $i$ ,  
A este mulțimea de adrese de memorie)

# Fișiere cu organizare directă

- *În practică*: e greu de definit astfel de funcții:
  - trebuie cunoscute de la început toate valorile posibile ale cheilor
  - pentru tabele mari este aproape imposibil de menținut bijectivitatea
- Soluție → sunt permise coliziunile:
$$h(K_i) = h(K_j), \text{ pt. } i \neq j \quad (h - \text{'funcție de dispersie'})$$
- Înregistrările cu valorile pentru cheie  $K_i$  și  $K_j$  se numesc *sinonime*

# Partiții (*buckets*)

- Toate înregistrările sinonime sunt stocate într-o partiție care începe la adresa returnată de  $h$ .
- O partiție este de obicei un bloc de memorie.



# Provocări ale organizării directe

- **Distribuirea** - odată ales algoritmul de dispersie se pierde controlul asupra distribuirii înregistrărilor pe partii.
- **Gruparea** - majoritatea înregistrărilor sunt plasate în aceeași parte și restul partiiilor conțin doar puține înregistrări.
- **Depășirea** - este posibilă depășirea spațiului de memorie alocat inițial unei parti.

# Definirea funcțiilor de dispersie

Cerințele pentru o funcție de dispersie ‘bună’:

- evaluare rapidă
- minimizează numărul de coliziuni

(dispersie uniformă a înregistrărilor pe partiții)

# Definirea funcțiilor de dispersie

Fie 41 partii goale unde adăugăm înregistrări:

- probabilitatea plasării înregistrării 1 într-o partitie goală e  $41/41$
- pentru ca și a doua înregistrare să fie plasată într-o partitie goală avem probabilitatea  $40/41$ ,
- pentru a treia înregistrare -  $39/41$ , etc.

Probabilitatea plasării a 8 înregistrări în 8 partii goale este :

$$(41/41)(40/41)(39/41) \dots (34/41) = 0.482$$

**⇒ sub 50%!!!**

# Definirea funcțiilor de dispersie

- Abordări:
  - Diviziune
  - Metoda pătratului (*mid-square*)
  - Împachetare (*folding*)
  - Multiplicare
- În general funcțiile de dispersie se aplică pe *reprezentarea binară* a cheii de căutare (de exemplu, pentru o cheie de căutare de tip text, se pot însuma reprezentările binare ale tuturor caracterelor acesteia iar rezultatul este transmis ca parametru funcției de dispersie).

# Definirea funcțiilor de dispersie

## ■ Diviziune:

- Funcții de forma  $h(k) = k \bmod N$
- Garantează plasarea rezultatului  $h(k)$  în intervalul  $[0 \dots N-1]$
- E ușor de calculat  $\Rightarrow$  cea mai populară abordare
- Dacă alegem  $N = 2^d$ , pentru un  $d$  număr natural oarecare, doar ultimii  $d$  biți ai lui  $k$  vor fi luati în considerare
- S-a arătat că numerele prime sunt cele mai potrivite ca valori ale lui  $N$

# Definirea funcțiilor de dispersie

## ■ Metoda pătratului (*mid-square*):

- Se ridică numărul la pătrat apoi se extrag  $l$  cifre din mijlocul rezultatului.
- $l = \text{lung}(k^2) - c_1 - c_2$  , unde  $c_1$  și  $c_2$  sunt reprezentă numărul celor mai puțin semnificative, respectiv cele mai semnificative cifre eliminate din pătratul lui  $l$
- $l$  și  $c_1$  sunt fixate de la început

# Definirea funcțiilor de dispersie

## ■ Împachetare (*folding*):

- Fiecare cheie  $k$  este partaționată în bucăți de lungimi egale (cu excepția ultimei)  $k_1, k_2, k_3, \dots, k_n$
- Funcția de dispersie e dată de formula

$$h(k) = (k_1 + k_2 + k_3 + \dots + k_n) \text{ mod } 10^l$$

unde  $10^l$  e numărul maxim de partiții

# Definirea funcțiilor de dispersie

## ■ Multiplicare

- Se extrage partea fracționară a numărului  $Z * k$  (pentru un  $Z$  specific) și se înmulțește cu  $N$  ( $N$  fiind numărul partițiilor):

$$h(k) = \lfloor N * (Z*k - \lfloor Z*k \rfloor) \rfloor = \lfloor N * \{Z*k\} \rfloor$$

- Cele mai bune rezultate se obțin pentru  
 $Z = (\sqrt{5} - 1)/2 = 0.61803\dots$  sau  $Z = (3 - \sqrt{5})/2 = 0.38196\dots$
- Pentru  $Z = Z'/2^w$  și  $N = 2^d$  ( $w$ : număr de biți într-un cuvânt)

$$h(k) = \text{msb}_d(Z'*k)$$

unde  $\text{msb}_d(x)$  reprezintă cei mai semnificativi  $d$  biți ai lui  $x$   
(exemplu: 42 a reprez. binară 101010,  $\text{msb}_3(42) = 5$  – binar 101)

## Definirea funcțiilor de dispersie

*Teoremă.* Având un număr irațional  $x$  și plasând  $\{x\}, \{2x\}, \dots, \{nx\}$  pe segmentul  $[0,1]$  se obțin  $n+1$  segmente ce au cel mult 3 dimensiuni diferite.

De asemenea, următoarea valoare,  $\{(n+1)x\}$ , va fi plasată pe unul dintre segmentele cu dimensiunea cea mai mare.

# Exemple de funcții de dispersie

- Valoare cheie ‘Toyota’
  - Concatenând reprezentarea numerică a caracterelor de pe primele două poziții obținem: Toyota  $\Rightarrow$ 

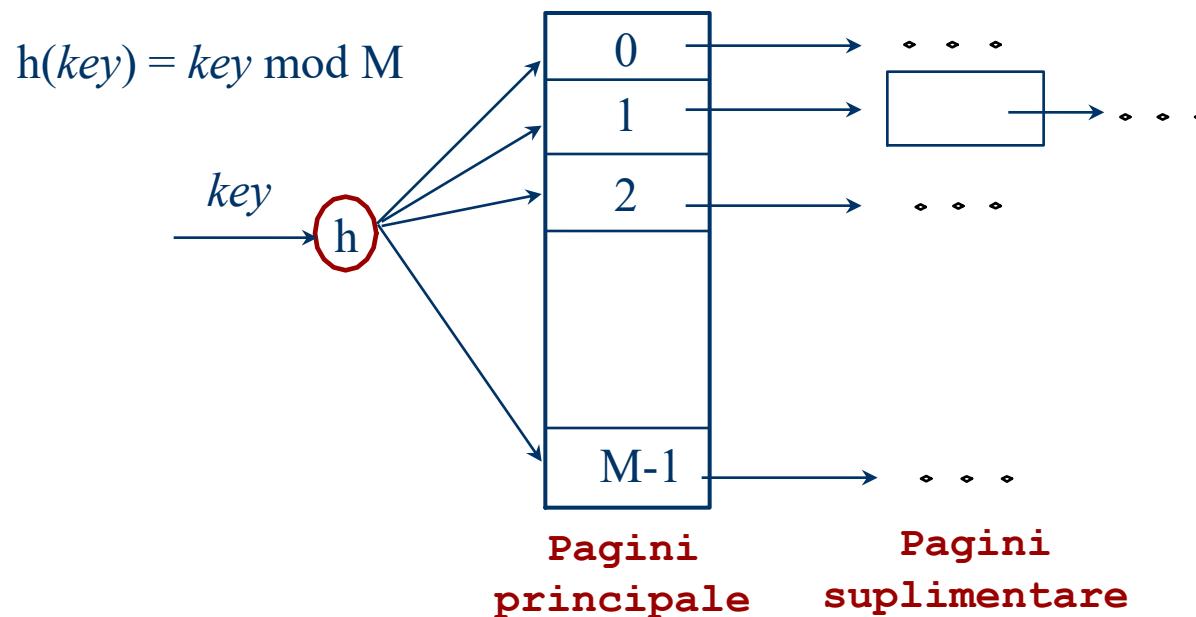
20	15
----	----
- Funcții de dispersie posibile
  - Diviziune: mod by 97  $\rightarrow$  **2015 mod 97 = 75**
  - Metoda pătratului: **2015<sup>2</sup> = 4060225**
  - Împachetare: **2015  $\rightarrow$  20+15 = 35**
  - Multiplicare:  **$\lfloor 99 * \{2015 * 0.61803\} \rfloor = 32$**
- De ce nu se utilizează **2015** ca valoare de dispersie?
  - 4 cifre  $\rightarrow$  10000 valori posibile!  $\rightarrow$  o bună parte a partițiilor vor fi goale
  - pentru cazul nostru 100 partiții sunt suficiente

# Rezolvarea coliziunilor

- Noile înregistrări se memorează într-o zonă suplimentară
- Se aplică o a doua funcție de dispersie pentru a obține o adresă “*second choice*”.
- Se memorează doar referințe (pointeri). La adresa returnată de funcția de dispersie avem:
  - Toți pointerii înregistrărilor sinonime – **partiție** de adrese.
  - Pointer către prima înregistrare. Aceasta va conține la rândul său un pointer către a doua înregistrare sinonimă, și.a.m.d. – **listă înlățuită**.
- Dispersie statică vs. dispersie dinamică

# Dispersie statică

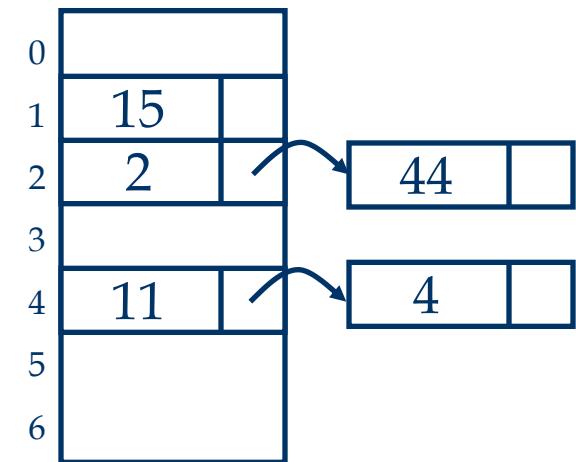
- Numărul paginilor/sloturilor *principale* e fix
- Paginile/sloturile sunt alocate secvențial, și nu sunt de-alocate; se pot utiliza pagini/sloturi *suplimentare* dacă este nevoie
- $h(k) = k \bmod M$  = partitia căreia îi aparține intrarea cu cheia  $k$ . ( $M$  = număr de partiții)



# Dispersie statică: Liste independente

- Toate sinonimele sunt stocate într-o listă înlățuită specifică
- Fișierul conține o listă de M intrări reprezentând capul unei liste de sinonime (partiții)
- Ordinea sinonimelor în listă poate fi:
  - ordinea de inserare
  - ordine descrescătoare a frecvenței de căutare
  - ordinea crescătoare a cheii de căutare (căutările fără succes se vor termina mai rapid)

k	$h(k) = k \bmod 7$
11	4
2	2
44	2
4	4
15	1

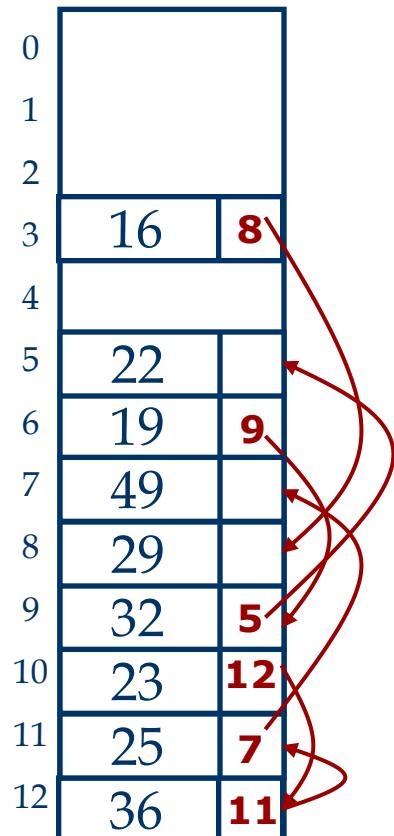


# Dispersie statică: Liste întrețesute

- Nu se utilizează pagini/sloturi suplimentare
- La inserarea unei noi intrări cu valoare cheii  $K$ :
  - Dacă slotul de la adresa  $h(K)$  e gol: se memorează înregistrarea
  - Dacă slotul de la adresa  $h(K)$  e ocupat:
    - se ocupă primul slot liber (căutând de la baza fișierului)
    - slotul ocupat e inserat la finalul listei ce conține slotul referit de  $h(K)$

Exemplu:

$k$	$h(k) = k \bmod 13$
16	3
23	10
36	10
25	12
19	6
32	6
29	3
49	10
22	9

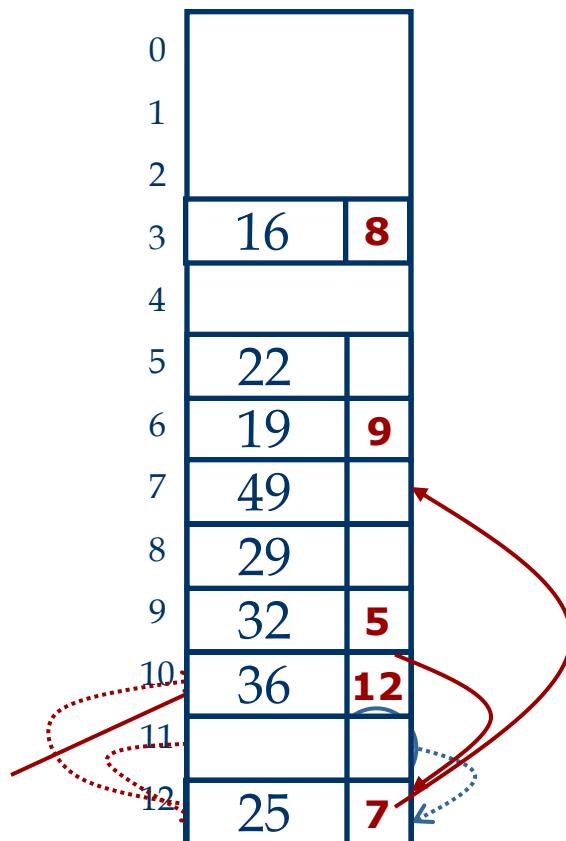


# Dispersie statică: Liste întrețesute

- Stergerea unei înregistrări cu valoarea cheii  $K$ :
  - Dacă slotul de la adresa  $h(K)$  e gol: mesaj de eroare
  - Dacă slotul  $h(K)$  e ocupat:
    - parcurgem lista pentru a căuta înregistrarea. Dacă aceasta nu e găsită: mesaj de eroare
    - 1. Dacă înregistrarea e găsită: se elimină
    - 2. Se caută, în continuarea listei, o înregistrare  $r$  cu  $h(K_r) = h(K)$ 
      - dacă e găsită
        - se mută înregistrarea în slotul curent.
        - se repetă pasul 2 pentru noul slot gol
    - 3. se copiază pointerul slotului gol în precedentul element din listă (dacă există)

# Dispersie statică: Liste întrețesute

- Exemplu: eliminarea cheii cu valoarea cheii 23.



k	$h(k) = k \bmod 13$
16	3
23	10
36	10
25	12
19	6
32	6
29	3
49	10
22	9

# Dispersie statică: Adresare deschisă

- Fișierul conține doare date (fără pointeri)
- Inserarea unei înregistrări cu valoarea cheii K:
  - Dacă slotul de la adresa  $h(K)$  e gol: se memorează înregistrarea
  - Dacă slotul de la adresa  $h(K)$  e ocupat se caută următorul slot liber la adresele  $h(K)+1, h(K)+2, \dots, M-1, 0, \dots, h(K)-1$ .
- Potrivit pentru ocupare de 75%

Exemplu:

$k$	$h(k) = k \bmod 13$
5	5
21	8
24	11
22	9
23	10
34	8
35	9

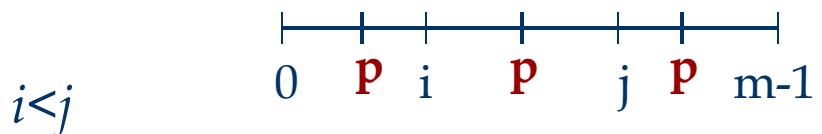
0	35
1	
2	
3	
4	
5	5
6	
7	
8	21
9	22
10	23
11	24
12	34

# Dispersie statică: Adresare deschisă

- Ştergerea unei înregistrări cu valoarea cheii K:
  - A. Înlocuirea valorii K cu un cod sau caracter special (vor trebui ajustați algoritmii de căutare și inserare pentru a interpreta corect valorile speciale)

# Dispersie statică: Adresare deschisă

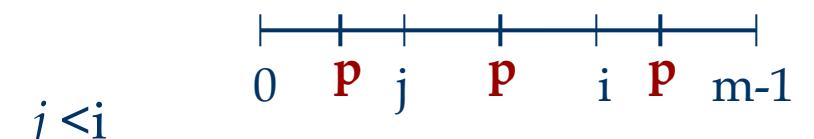
- Ștergerea unei înregistrări cu valoarea cheii K:
  - A. Înlocuirea valorii K cu un cod sau caracter special (vor trebui ajustați algoritmii de căutare și inserare pentru a interpreta corect valorile speciale)
  - B. Se elimină înregistrarea și se fac transferuri de înregistrări astfel ( $i, j, p$  sunt adrese de memorie):
    - $i$  e adresa înregistrării sterse,
    - nu sunt sloturi goale între  $i$  și  $j$
    - înregistrarea stocată la  $j$  trebuie să fie stocată la  $p$



$i < p \leq j : -$

$j \leq p \leq m-1 : \text{înreg. din } j \text{ se transferă la } i$

$0 \leq p \leq i : \text{înreg. din } j \text{ se transferă la } i$



$0 < p \leq j : -$

$j < p \leq i : \text{înreg. din } j \text{ se transferă la } i$

$i < p \leq m-1 : -$

# Concluzii asupra dispersiei statice

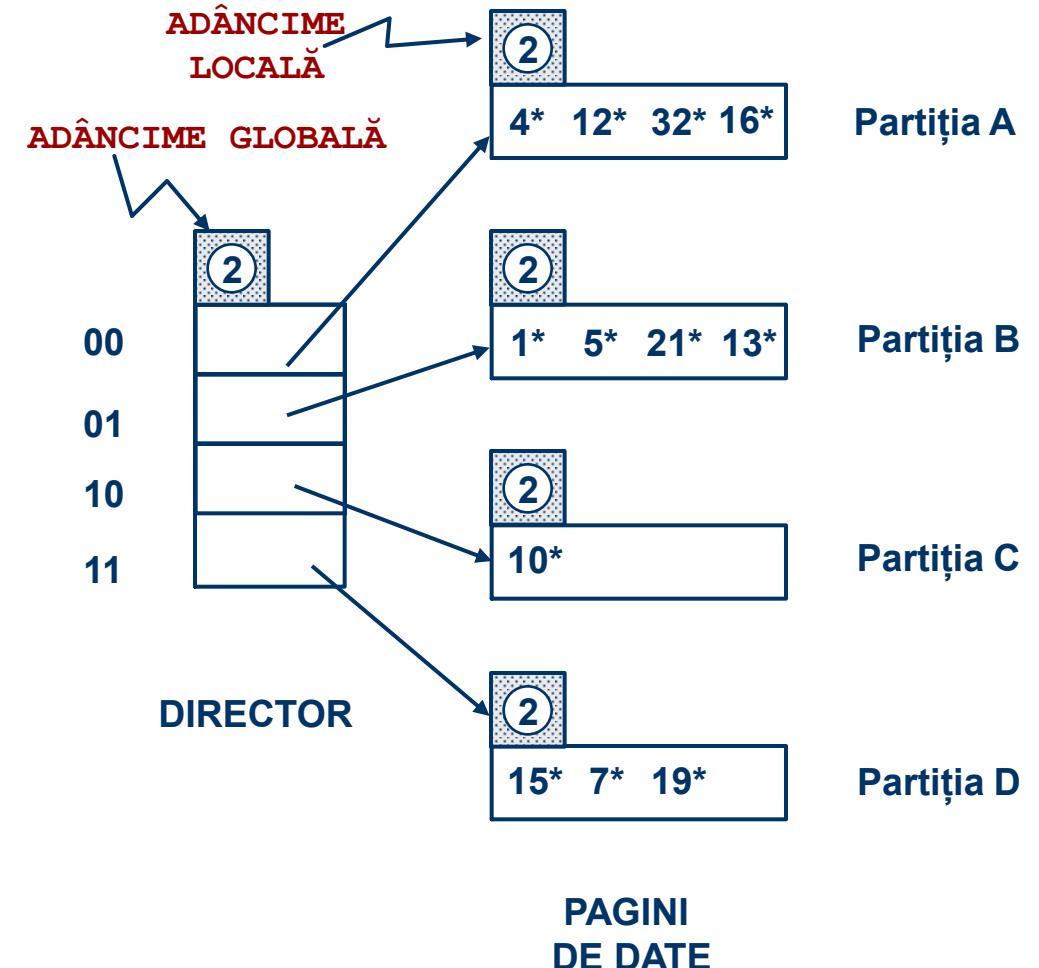
- Partițiile conțin *înregistrări*.
- Dacă se adaugă multe *înregistrări*, se formează liste de pagini de memorie suplimentare (crește numărul de pagini transferate în memoria internă).
- Similar, dacă numărul *înregistrărilor* descrește semnificativ, este o risipă de spațiu de stocare (sloturile din partiții rămân nealocate).
- *Dispersie extensibilă și liniară*: tehnici dinamice de abordare a dezavantajelor dispersiei statice.

# Dispersie extensibilă

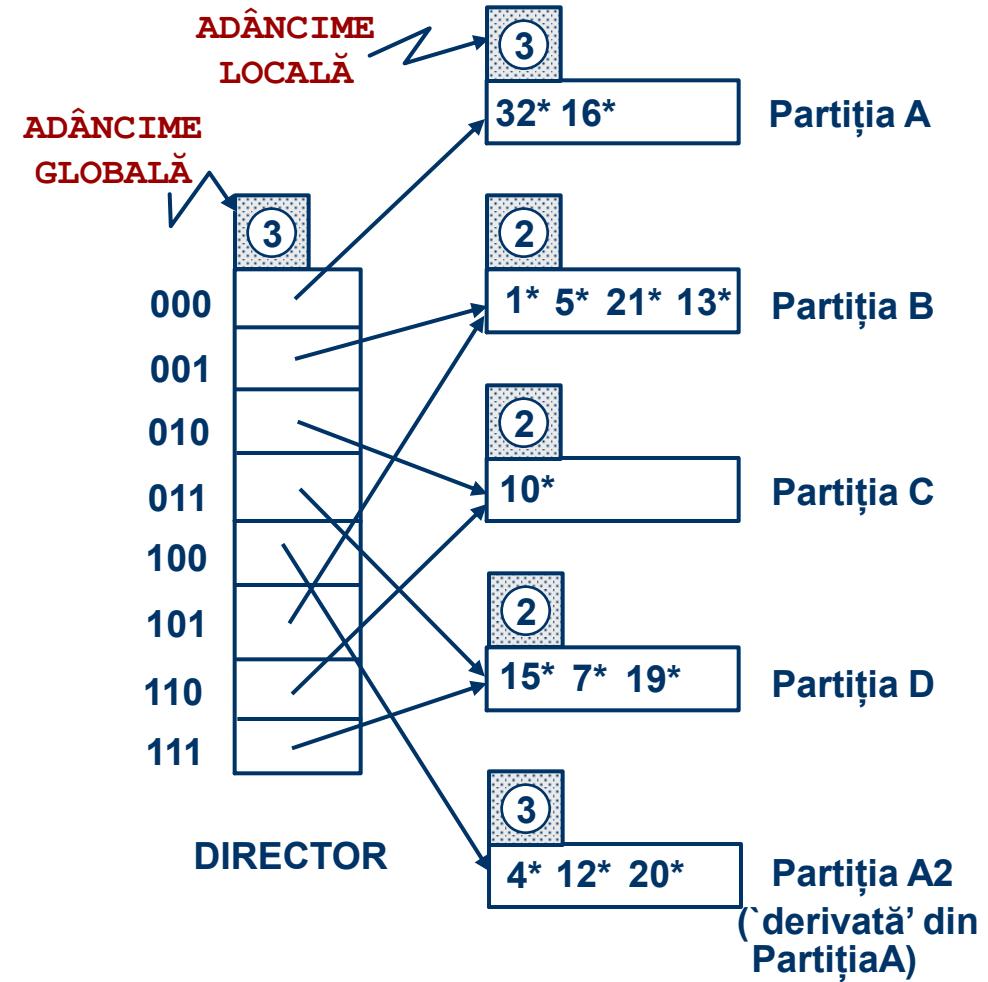
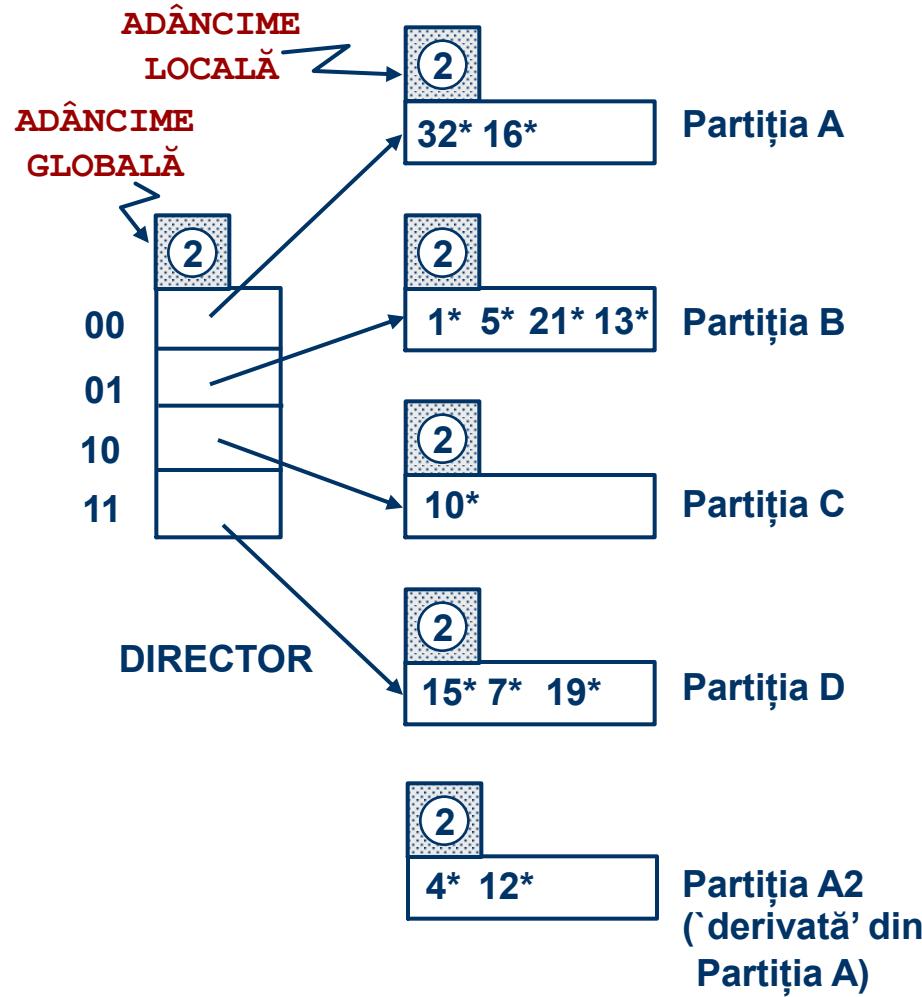
- Idee: Dacă partiiile primare devin neîncăpătoare, fișierul se reorganizează prin *dublarea* numărului de partii
  - Fișierul va conține un *director de pointeri la partii*,
  - Dublarea numărului de partii se realizează prin *dublarea directorului*,
  - Se distribuie înregistrările doar din partea ce a devenit neîncăpătoare
  - *Nu există pagini suplimentare!*
  - Funcția de dispersie va fi ajustată corespunzător

# Exemplu

- Directorul are dimensiunea 4.
- Pentru a determina partitia lui  $r$ , se iau in considerare ultimii biti din reprezentarea binara a lui  $h(r)$  (numarul de biti luati in considerare e dat de '*adancimea globala*').
  - Daca  $h(r) = 5$  = binar 101, se afla in partitia referita de 01.
- Inserarea: Daca partitia e plina, acesta se imparte in doua (se alocă o nouă pagină și se redistribuie înregistrările).
- *Dacă e necesar*, directorul se dublează. (doar cand *adancimea globală* devine mai mică decât *adancimea locală* a noii partitii)



# Inserare k: $h(k) = 20 \rightarrow$ Dublare



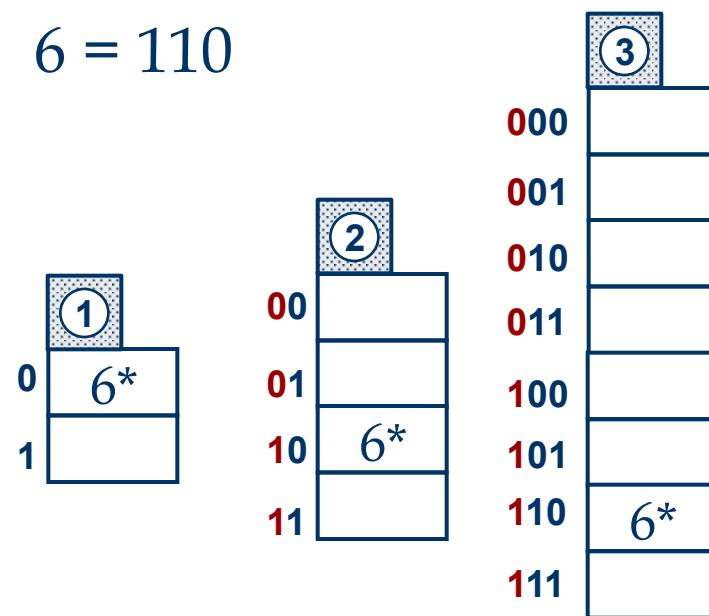
# Dispersie extensibilă

- Inserare  $h(k) = 20$  (binar 10100). Ultimii **2** biți (00) arată că  $r$  aparține lui A sau A2. E nevoie de ultimii **3** biți pentru a identifica partitura potrivită.
  - *Adâncimea globală a directorului*: numărul maxim de biți necesari pentru a determina partitura căreia îi aparține o înregistrare.
  - *Adâncimea locală a partituriei*: numărul de biți utilizați pentru a determina dacă o înregistrare aparține partituriei.
- În ce condiții adăugarea unei noi partiturii implică dublarea directorului?
  - Înaintea inserării, *adâncimea locală* partituriei = *adâncimea globală*. Inserarea face ca *adâncimea locală* să devină  $>$  *adâncimea globală*; directorul se dublează prin copiere

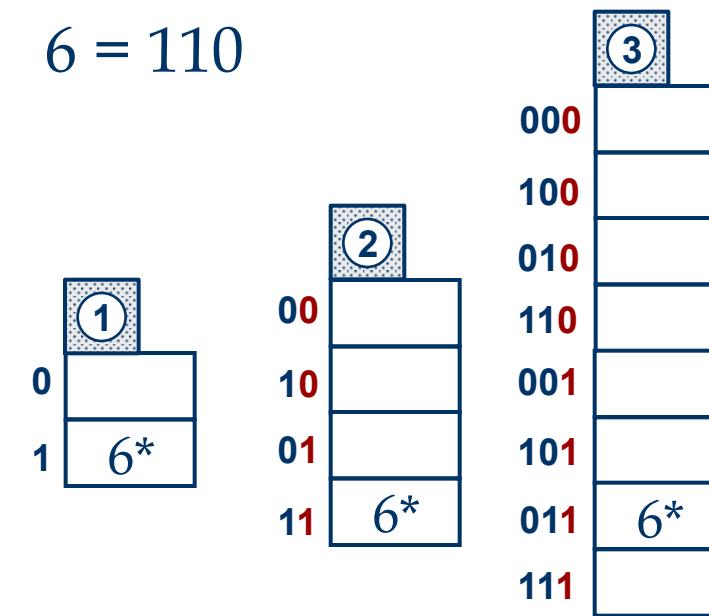
# Dublarea directorului

- Utilizarea celor mai puțin semnificativi biți → dublarea directorului se realizează prin copiere!

$6 = 110$



$6 = 110$



Cel mai puțin semnificativ

vs.

Cel mai semnificativ

# Comentarii despre dispersia extensibilă

- Dacă directorul încape în memoria internă, interogările bazate pe egalități au nevoie de un singur acces la disc (suport extern);
  - Directorul crește brusc iar dacă distribuția valorilor funcției de dispersie nu e una normală, directorul se poate mări excesiv.
  - Sinonimele multiple pot crea probleme!
- **Stergeri:** Dacă la eliminarea unei înregistrări o partitură se golește, aceasta poate fuziona cu perechea sa (ținând cont de valorile ultimilor biți ai adâncimii locale). Dacă toate adâncimile locale sunt mai mici decât adâncimea globală, directorul se poate înjumătăti.

# Evaluarea fișierelor cu organizare directă

- Avantaje:
  - Acces foarte rapid
  - Cea mai bună soluție pentru *interogări cu egalități*

```
SELECT * FROM R WHERE A = k
```

deoarece (în general) indiferent de numărul de înregistrări adăugate sau șterse, răspunsul la interogare va fi dat de citirea unei singure pagini de memorie de pe suportul extern.

# Evaluarea fișierelor cu organizare directă

## ■ Dezavantaje:

- Ordinea secvențială a înregistrărilor nu are nici o semnificație
- Fișierele cu organizare directă sunt deseori fragmentate.
- Nu suportă interogări cu intervale.
- Nu sunt recomandate atunci când câmpul transmis ca parametru funcției de dispersie este actualizat frecvent